PORTFÓLIO · 2026

Diego Hamed de Assis Brasil

Staff Software Engineer — IA aplicada, LLMs, processamento de documentos e imagens, arquitetura de sistemas.

— Porto Alegre, RS · Brasil — diegohabrasil@gmail.com — linkedin.com/in/dhabrasil

HOJE	FORMAÇÃO	FOCO
Staff Software Engineer e sócio · Planton	Eng. Elétrica + Especialização em Eng. de Software · PUCRS	Agentes de LLM, busca semântica, documentos, system design

SOBRE

Construo produtos de IA que transformam dados heterogêneos — planilhas, PDFs, fotos, áudio, texto livre — em informação estruturada, rastreável e pronta para decisão.

Venho da engenharia elétrica e do hardware, passei por backend, dados e MLOps, e hoje atuo do desenho do sistema ao código de produção: agentes de LLM, recuperação de informação, pipelines de ingestão e arquiteturas que continuam saudáveis quando boa parte do código é escrita em parceria com agentes de IA.

ÁREAS DE ATUAÇÃO

01

LLMs e agentes

Agentes especializados orquestrados com LangChain e LangGraph, com ferramentas e saída estruturada validada por schema.

RAG com gestão de contexto e de conhecimento para agentes.

Busca híbrida: lexical (BM25) + vetorial, fusão de rankings, rerank e LLM como juiz.

Classificação hierárquica: o modelo desce uma taxonomia escolhendo entre poucos ramos por nível, em vez de encarar o catálogo inteiro.

Multi-provedor atrás de portas e adaptadores: provedores de nuvem, APIs de mercado e modelos locais.

02

Documentos e imagens

Ingestão multiformato: XLSX, CSV, PDF, DOCX, JPEG e PNG com Docling, PyPDF, Unstructured e OCR.

OCR em cascata: um modelo localiza a região de interesse, outro reconhece os caracteres.

Extração com LLM de documentos financeiros e operacionais, inclusive com modelos locais para privacidade total.

Normalização de texto livre: forma canônica, unidades, sinônimos e reescrita assistida por LLM antes do match.

03

Arquitetura

Camadas com dependência para dentro (api → application → domain) e infraestrutura isolada.

Fitness functions no CI: scripts que verificam tamanho de arquivo, direção de imports e isolamento do ORM.

Assíncrono com mensageria sobre PostgreSQL; sistemas cloud-native em AWS e GCP.

Rastreabilidade: cada decisão grava trace, tokens, custo, latência e versão do modelo.

Tipagem estrita (mypy strict, Pydantic) e testes como contrato.

PADRÃO RECORRENTE · CORRESPONDÊNCIA DE TEXTO LIVRE CONTRA CATÁLOGO TÉCNICO



Toda chamada externa é cacheada pelo hash do payload, com temperatura zero e teto de gasto por execução. A mesma entrada com a mesma configuração gera sempre a mesma saída, e o limiar de auto-aceite é calibrado para uma precisão-alvo.

TRABALHOS EM DESTAQUE

LLM · BUSCA SEMÂNTICA · AVALIAÇÃO

Correspondência entre itens descritos em texto livre e um catálogo técnico de referência

Clientes descrevem compras em português, cada um do seu jeito; cada item precisa ser ligado ao equivalente num catálogo técnico em inglês. Desenhei e implementei duas estratégias concorrentes sobre a mesma base, comparadas pela mesma régua:

- **Descida hierárquica**: o LLM percorre uma taxonomia internacional de produtos, decidindo entre poucos ramos por nível; barata e explicável.
- **Busca híbrida + juiz**: BM25 e embeddings, fusão de rankings, rerank e um LLM que escolhe entre os finalistas ou declara "sem correspondência".
- **Harness de benchmark** com dataset dourado, split dev/test protegido contra vazamento, precisão@1, recall@10, cobertura com precisão ≥ 95% e intervalos de confiança.
- **Engenharia de custo**: cache por hash, teto de gasto, verificação de idempotência, preço por modelo versionado.

`Python 3.13` `LLM gerenciado` `Embeddings + rerank` `BM25` `NumPy` `Pydantic` `SQLite` `mypy strict`

AGENTES · PRODUTO

Plataforma de agentes de IA para dados corporativos

Sistema web de ponta a ponta com agentes de LLM especializados, adotado por várias empresas. Recebe o dado no formato em que ele já existe — chat, formulário, PDF, planilha, integração com ERP — e entrega um resultado rastreável até a linha de origem.

`LangGraph` `RAG` `FastAPI` `Next.js` `PostgreSQL`

VISÃO COMPUTACIONAL · OCR

Leitura de medidores de energia por foto de celular

Prova de conceito de OCR em cascata: um primeiro modelo encontra a região de interesse no visor, um segundo lê os caracteres dentro dela. Objetivo: permitir autoleitura pelo cliente e registro de leitura em campo com uma única foto.

`Python` `Tesseract` `ROI` `Android`

MLOPS · DADOS · EMERGÊNCIA

Do áudio do atendimento à informação, durante as enchentes no RS

Pipeline emergencial: transcrição do atendimento ao cliente com speech-to-text, ETL com LLM para transformar conversa em dado estruturado, carga em PostgreSQL e depois migração para BigQuery. Orquestração completa em Apache Airflow.

`Speech-to-text` `OpenAI` `Airflow` `BigQuery` `GCP`

ARQUITETURA · ENGENHARIA COM AGENTES

Guardrails de arquitetura para código escrito por LLMs

Testes unitários introduzidos numa base legada, de 0% a mais de 20% de cobertura, e scripts de validação de arquitetura no CI: limite de tamanho de arquivo, direção de dependências, ORM sem regra de negócio. Os agentes rodam as verificações após cada mudança e refazem o trabalho quando falham.

`CI` `Fitness functions` `FastAPI` `SQLModel` `Claude Code`

OPEN SOURCE · EXTRAÇÃO DE DOCUMENTOS

Organizador de investimentos para a declaração de IR

Você envia os PDFs de corretoras e bancos e o sistema organiza cada ativo pelo código correspondente na declaração. Funciona com modelos locais via Ollama, com privacidade total e banco SQLite local, ou com modelos de mercado da Anthropic e da OpenAI. Roda via docker-compose. Código aberto a contribuições.

`LLM` `Ollama` `Anthropic` `OpenAI` `SQLite` `Docker`

EXPERIÊNCIA

jul 2026 — hoje
abr 2025 — jul 2026

Staff Software Engineer · Software Engineer

Planton · Porto Alegre · sócio desde 2026

- Pipelines de ingestão de dados estruturados e não estruturados (XLSX, PDF, DOCX, JPEG, PNG) com Docling, PyPDF, Unstructured e OCR.
- Sistemas web de ponta a ponta com agentes de LLM especializados, adotados por várias empresas; orquestração com LangChain e LangGraph.
- Sistemas RAG, incluindo gestão de contexto e conhecimento para agentes.
- Arquiteturas assíncronas com mensageria sobre PostgreSQL; sistemas cloud-native com princípios de design distribuído.
- Liderança de system design para transformar soluções em produtos escaláveis; aplicações full stack com FastAPI e Next.js.
- Uso intensivo de agentes de código (Claude Code, Claude Cowork, TRAE) e criação de "skills" reutilizáveis para acelerar o fluxo de engenharia.

dez 2023 — abr 2025

Fullstack Developer

Grupo Equatorial Energia · Porto Alegre

- Pipeline emergencial de MLOps/ETL em torno de speech-to-text e LLM para o atendimento durante as enchentes no RS; PostgreSQL → BigQuery; Apache Airflow.
- OCR em cascata (ROI + reconhecimento de caracteres) para leitura de medidores por foto.
- GCP, Vertex AI, Next.js, Android.

jun 2022 — dez 2023

Software Developer

CWI Software · Porto Alegre

- Migração de um microsserviço de vendas de PHP para Python, com novas funcionalidades e reforço de segurança.
- Módulos em C para integração com APIs de parceiros: ativação, suspensão, cancelamento e reativação de pacotes.
- Evolução de um sistema legado de carrinho de compras usado por milhares de pessoas; Jenkins, SonarQube, Docker, Linux CLI e VIM.

2018 — 2022

Engenharia, P&D e excelência operacional

Antes do software

fev 2021 — mar 2022 — **Gerdau** · automação e análise de dados com Power BI, Power Apps e Power Automate; Scrum, A3, Kaizen.

jul 2019 — jul 2020 — **TDK** · desenvolvimento de capacitores de polímero, testes de vida útil e estresse, análise em Minitab.

nov 2018 — jun 2019 — **CEDER · PUCRS** · pesquisa em energia solar, eólica, bancos de baterias e eficiência energética.

abr — out 2018 — **Governo do RS** · projetos elétricos e laudos de vistoria para escolas públicas.

PALESTRAS E CONTEÚDO

set 2026

IA aplicada: dados complexos em produtos escaláveis

Semana Caldeira 2026, Instituto Caldeira, Porto Alegre. Como uma arquitetura de dados bem construída sustenta um produto de IA em produção.

mai 2026

Aplicação de IA no inventário de emissões

Episódio de podcast sobre o uso de LLMs para automatizar trabalho analítico intensivo em dados.

mai 2026

Auditoria automática de arquitetura para código gerado por LLM

Artigo sobre testes e fitness functions no CI para manter modularidade e evitar dívida técnica quando agentes escrevem código.

FORMAÇÃO

2024 — 2025

Especialização em Engenharia de Software

PUCRS · pós-graduação lato sensu, desenvolvimento full stack

2016 — 2023

Bacharelado em Engenharia Elétrica

PUCRS · eletrônica, microcontroladores (Arduino, ESP8266, STM32)

COMPETÊNCIAS

IA E LLMS

LangChain, LangGraph, RAG, embeddings, rerank, LLM como juiz, saída estruturada, avaliação com dataset dourado, AWS Bedrock, OpenAI, Gemini, Ollama, Vertex AI

DOCUMENTOS E IMAGENS

OCR (Tesseract), Docling, PyPDF, Unstructured, detecção de região de interesse, extração de PDF e planilhas, speech-to-text

BACKEND E WEB

Python, FastAPI, Flask, Pydantic, SQLAlchemy, SQLModel, TypeScript, JavaScript, Next.js, C

DADOS

PostgreSQL, BigQuery, SQLite, Apache Airflow, ETL, Polars, NumPy, BM25

INFRA E ENTREGA

Docker, AWS, GCP, Terraform, Ansible, Jenkins, SonarQube, GitHub, Linux

PRÁTICA DE ENGENHARIA

System design, arquitetura em camadas, TDD, mypy strict, fitness functions, engenharia com agentes de código, liderança técnica

Diego Hamed de Assis Brasil

diegohabrasil@gmail.com · linkedin.com/in/dhabrasil